

SQL4Business

Asistente de consultas: SQL y reportes ejecutivos fieles a los datos

Generative Artificial Intelligence (580694), Universidad de Concepción | Deliverable 1

Equipo: Aredhel Jiménez, Bryan Riquelme, Guido Salazar, Vicente Soñez

Repositorio: github.com/aredhel-jmze/Asistente-SQL-4-Business

Definición de la tarea

Se propone un asistente que, dada una pregunta de negocio, decide y ejecuta las consultas SQL necesarias, y redacta un resumen fiel a los resultados obtenidos, ya sea para una consulta puntual o para una consulta combinada, que requiere identificar, relacionar y ejecutar varias consultas para razonar cuál es la respuesta correcta. Una salida se consideraría correcta cuando las consultas ejecutadas son las necesarias y suficientes para responder la pregunta, y cuando cada cifra del resumen final es fiel a esos resultados.

Diferenciación del proyecto

Text-to-SQL es una tarea ampliamente estudiada, pero la literatura existente se detiene casi siempre en la exactitud de una única consulta generada. Este proyecto extiende esa base en dos direcciones poco exploradas en modelos abiertos pequeños. La primera es la capacidad de planificar qué consultas son necesarias para responder preguntas que combinan varios datos, como el crecimiento de ventas del último semestre, y la segunda es la fidelidad numérica del reporte generado a partir de esos resultados.

Diagnóstico de la falla

Un modelo abierto de hasta 8B promptado directamente falla en ambas direcciones. Sobre el benchmark BIRD (95 bases de datos reales con valores ruidosos) [6], estos modelos no superan el 51% de exactitud de ejecución en una sola consulta, lejos del 90% o más que alcanzan sistemas con modelos mucho más grandes [1], y la caída es mayor en consultas con agregación y joins (cuando se deben combinar datos de múltiples filas o de distintas tablas), donde un modelo de 7B pasa de 69.2% en consultas simples a 54.5% en moderadas [2]. Cuando la pregunta exige planificar y encadenar varias consultas, como en una consulta combinada, la falla se agrava, y en evaluaciones de function calling multi turno, modelos pequeños sin especializar caen a precisiones de un solo dígito, aunque el mismo modelo resuelva bien una llamada aislada [3]. Esto se confirma con evidencia propia sobre 15 preguntas de negocio construidas por el equipo (10 puntuales, 5 combinadas), resumida en la siguiente tabla.

Modelo	Puntual	Combinada	Global
Qwen-7B	50%	0%	33.3%
Qwen-3B	70%	0%	46.7%
Llama-8B	70%	0%	46.7%

Los tres modelos, sin excepción, obtuvieron 0% en las preguntas combinadas.

En la etapa de redacción del resumen, incluso con las consultas correctas, el modelo puede introducir cifras que no corresponden a los resultados reales obtenidos. Este problema no es incidental ni parejo entre tamaños: un estudio reciente muestra que la inconsistencia factual en generación de texto a partir de datos estructurados escala de forma exponencial, no lineal, a medida que el modelo se achica [4], lo que sitúa a un modelo de 8B o menos en una zona de riesgo particularmente alta.

Modelos candidatos

Se seleccionan tres modelos que cubren roles distintos, no solo el mejor puntaje, mayor exactitud publicada, menor tamaño para el bonus, y mayor soporte de comunidad para reducir el riesgo de ejecución.

Modelo	B	EX BIRD	Justificación
Qwen2.5-Coder-7B-Instruct	7	50.9% [1]	Mejor exactitud publicada entre modelos $\leq 8B$; contexto de 128K [5]; notebooks QLoRA disponibles
Qwen2.5-Coder-3B-Instruct	3	no reportado	Misma familia y datos que el principal; aísla el efecto del tamaño (bonus) e itera más rápido
Llama-3.1-8B-Instruct	8	42.0% [1]	Menor exactitud, pero mayor comunidad y documentación de fine-tuning; menos riesgo de ejecución

Factibilidad de ejecución

Los tres candidatos, cuantizados en 4 bits, ocupan entre 2 y 5GB de VRAM, dentro del límite de una GPU T4 de 16GB de Google Colab gratuito. El fine-tuning con QLoRA sobre Qwen2.5-Coder-7B-Instruct es viable en una sola sesión, con notebooks de referencia públicos para text-to-SQL sobre BIRD. Para el fine-tuning se usará un subconjunto de 10 a 15 bases de datos de BIRD del dominio de negocio (ventas, inventario, finanzas), evitando cargar el benchmark completo (33.4GB); el diagnóstico de falla de este entregable, en cambio, se evaluó sobre la base de datos sintética propia del equipo. Dada la velocidad de iteración y que la evidencia propia no muestra desventaja frente a los otros candidatos, el equipo se inclina por Qwen2.5-Coder-3B-Instruct para las siguientes etapas del semestre.

Repositorio

El repositorio documenta la tarea, el equipo, y el estado del trabajo, incluyendo el notebook de evaluación baseline y los resultados de los tres candidatos.

Referencias

- [1] “CogniSQL-R1-Zero: Lightweight Reinforced Reasoning for Efficient SQL Generation.” arXiv:2507.06013, 2025.
- [2] “JudgeSQL: Reasoning over SQL Candidates with Weighted Consensus Tournament.” arXiv:2510.15560, 2025.
- [3] “TinyLLM: Evaluation and Optimization of Small Language Models for Agentic Tasks on Edge Devices.” arXiv:2511.22138, 2025.
- [4] Mahapatra, Roy, Garain. “Factual Inconsistency in Data-to-Text Generation Scales Exponentially with LLM Size.” arXiv:2502.12372, 2025.
- [5] Hui, Yang, et al. “Qwen2.5-Coder Technical Report.” arXiv:2409.12186, 2024.
- [6] Li et al. “Can LLM Already Serve as A Database Interface? A Big Bench for Large-Scale Database Grounded Text-to-SQLs.” NeurIPS 2023 (arXiv:2305.03111).