


# SQL4Business: Deliverable 2

Generative Artificial Intelligence (580694), Universidad de Concepción

Aredhel Jiménez, Bryan Riquelme, Guido Salazar, Vicente Soñez

Código: [github.com/aredhel-jmze/Asistente-SQL-4-Business](https://github.com/aredhel-jmze/Asistente-SQL-4-Business) | Video: [Google Drive](#)



**Tarea, falla y modelo.** Sin cambios respecto del Deliverable 1: responder preguntas de negocio puntuales y combinadas ejecutando el SQL necesario y reportando solo cifras fieles a los resultados. Con prompting directo, los tres candidatos obtuvieron 0/5 en preguntas combinadas (años inventados, etiquetas traducidas, dialectos de otros motores, una sola consulta para una pregunta de varios valores). Nos comprometemos con **Qwen/Qwen2.5-Coder-3B-Instruct** (revisión 488639f, NF4 de 4 bits, cómputo bf16, decodificación greedy, Colab T4): es el menor candidato y empató el mejor baseline propio (46.7%); Qwen-7B obtuvo 33.3% y Llama-8B también 46.7%, con más parámetros y acceso restringido.

**Intervención.** Cada componente ataca un error diagnosticado. El esquema enriquecido entrega las etiquetas exactas, el rango de fechas y las llaves de unión (etiquetas traducidas, años inventados). El planificador descompone la pregunta en pasos SQL y nombra una operación; el código, no el modelo, calcula crecimiento, participación, comparación y filtro con ranking (preguntas combinadas, aritmética mental). SQLite se ejecuta en solo lectura; los errores de validación o de forma vuelven al planificador hasta dos veces. Un paso posterior puede leer uno anterior (**FROM step\_1**), que se expande como CTE. El reportero escribe en el idioma de la pregunta, y la verificación acepta una cifra solo si coincide con la respuesta verificada o con la evidencia a la precisión escrita, y controla la dirección del cambio.

**Evaluación.** Set oficial: las 15 preguntas del Deliverable 1 (10 puntuales, 5 combinadas), usadas durante el desarrollo, por lo que es in-sample. Set externo: 12 paráfrasis (5/7) con la misma referencia, escritas en una auditoría y no usadas para el diseño. Todos los sistemas reciben las mismas entradas y criterios: *sql* es el criterio del Deliverable 1 (cada resultado de referencia se produce exactamente); *answer* revisa la respuesta final, sin importar cómo se obtuvo; *report* y *e2e* (respuesta y reporte correctos) se aplican a la solución. El baseline es el prompt del Deliverable 1, literal; la estrategia alternativa solo le agrega el esquema enriquecido.

**Resultados (tabla inferior).** La solución responde 11/15 preguntas oficiales y 10/12 externas, frente a 8/15 y 5/12 del baseline; en combinadas, 2/5 y 5/7 frente a 1/5 y 2/7. Responde y reporta fielmente en 10/15 y 10/12. El esquema enriquecido explica la

mayor parte de la mejora en puntuales (9/10 respuestas oficiales); la descomposición suma las combinadas. Costo en la T4: 16.3s por pregunta frente a 6.2s del baseline.

**Desviaciones declaradas.** (1) La primera versión (17-09) elegía la operación con palabras copiadas de las 5 preguntas combinadas y vetaba otros planes: 12/15 in-sample, pero 0/7 en paráfrasis combinadas. Se eliminó. (2) Esa versión usaba además un nuevo prompt de baseline en inglés (40%); se restituyó el prompt del D1. (3) Se agregó la métrica *answer* porque el criterio *sql* rechaza respuestas correctas de una sola consulta (el baseline responde bien q14). (4) No se aplicó el fine-tuning QLoRA previsto en el D1. (5) La primera corrida de esta versión (v2) descartó reportes en texto plano por no ser JSON; v3 solo cambia el formato de salida del reportero, y su SQL y respuestas son idénticos a v2 en 27/27 preguntas.

**Caso de falla: q09.** El planificador filtra con `strftime('%Y-%m', sale_date) BETWEEN '2026-03-01' AND '2026-05-31'`. Comparar '2026-03' con una fecha completa deja fuera marzo y junio, por lo que el código calcula un crecimiento de 70.06% en vez de 60.13%. El SQL es válido, el resultado es un solo número y el reporte es fiel a él, de modo que ni la validación, ni la reparación, ni la verificación detectan el error: revisan forma y cifras, no el significado de un predicado. En q10 el modelo vuelve a usar `strftime('%Q')` pese al mensaje de error, y en q09-p (externa) planifica un solo paso, por lo que el crecimiento nunca se calcula; su reporte inventa 26%, 10% y 12%, y la verificación lo rechaza.

**Límites.** Los resultados oficiales son in-sample y ambos sets son pequeños (27 preguntas, datos sintéticos). La verificación controla cifras, no su atribución: en q11 acepta 488 presentado como total, y en q14-p un id de producto tomado de un paso. Además es conservadora: rechaza "paso 1" en q13. Cuando el planificador elige *direct* para una pregunta combinada, la respuesta depende de una sola consulta. Los reintentos rara vez corrigen un plan (sesgos fuertes del modelo).

**Reproducción.** `notebooks/deliverable2_demo.ipynb` en una T4 de Colab (*Run all*, unos 25 min) clona el repositorio, corre la demo del video y la evaluación, y escribe `results/deliverable2_v3.json` y la tabla inferior; no requiere subir archivos ni tokens.

| Sistema                              | Métrica | Set oficial (in-sample) |           |       | Paráfrasis (held-out) |           |
|--------------------------------------|---------|-------------------------|-----------|-------|-----------------------|-----------|
|                                      |         | Puntual                 | Combinada | Total | Puntual               | Combinada |
| Prompt directo (baseline D1)         | sql     | 7/10                    | 0/5       | 7/15  | 3/5                   | 0/7       |
|                                      | answer  | 7/10                    | 1/5       | 8/15  | 3/5                   | 2/7       |
| Prompt directo + esquema enriquecido | sql     | 8/10                    | 0/5       | 8/15  | 4/5                   | 0/7       |
|                                      | answer  | 9/10                    | 1/5       | 10/15 | 4/5                   | 4/7       |
| Solución estructurada                | sql     | 9/10                    | 2/5       | 11/15 | 5/5                   | 3/7       |
|                                      | answer  | 9/10                    | 2/5       | 11/15 | 5/5                   | 5/7       |
|                                      | report  | 8/10                    | 4/5       | 12/15 | 5/5                   | 6/7       |
|                                      | e2e     | 8/10                    | 2/5       | 10/15 | 5/5                   | 5/7       |